



פרויקט בסימולציה - בדיקות קורונה

קבוצה 17



מרצה: דר' נמרוד טלמון

תאריך: 10/1/2021

מגשים:

עמית קפון 307994947

נאור פינטו 315625301

רן יהלומי 307983114

תוכן עניינים

4	3. תקציר
4	4. מבוא
4	4.1 תיאור המערכת הנחקרת
5	4.2 מטרות
6	5. מודל הסימולציה
6	5.1 תיאור המודל
7	5.2 הנחות
8	6. ניתוח מצב קיים והצעת חלופות
8	6.1 בחירת מדדים לניתוח
9	6.2 סוג המערכת
9	6.3 ניתוח מצב קיים ביחס למדדים ולמטרות
10	6.4 תיאור החלופות
11	6.5 השוואה סטטיסטית בין מצב קיים לחלופות מוצעות
12	7. מסקנות
13	8. נספחים
13	נספח 4.1.1 – קצב הגעה וזמן בדיקת קורונה
13	נספח 4.1.2 – מבנה הדרייב-אין
13	נספח 4.1.3 – פריסת קופות החולים
14	נספח 4.1.4 – זמני נסיעות והעברת בדיקות
14	נספח 4.1.5 – מבנה המעבדה
14	נספח 4.1.6 – זמן פענוח הבדיקה והתפלגות התוצאות
15	נספח 5.1.1 – מחולל הישויות
15	נספח 5.1.2 – מסלול CovidTest
15	נספח 5.1.3 – מסלול Mega Drive-In
16	נספח 5.1.4 – מסלול MDA
16	נספח 5.1.5 – מסלול קופת חולים ראשי
17	נספח 5.1.6 – מסלול שהישות עוברת בקופת חולים
17	נספח 5.1.7 – מסלול עזיבת המערכת
17	נספח 5.1.8 – מסלול הבידוד
18	נספח 5.1.9 – הישויות השונות במערכת

נספח 5.1.10 – מציאת התפלגות קצב הגעת הישויות לDrive-In	19
נספח 5.1.11 – מציאת התפלגות קצב הגעת הישויות שיש להם סימפטומים למד"א	21
נספח 5.1.12 – המשאבים השונים	23
נספח 6.1.1 – מדד אורך תור ממוצע במד"א	24
נספח 6.1.2 – מדד זמן המתנה ממוצע בתור לקופות החולים	24
נספח 6.1.3 – מדד אורך תור ממוצע במעבדת מרכז	25
נספח 6.2.1 – קביעת זמן החימום	25
נספח 6.2.2 – חישוב הדיוק היחסי עבור כל מדד	28
נספח 6.2.3 – חישוב דיוק יחסי עבור כל השוואה, ערכי ממוצע וסטיית התקן עבור המדדים	28
נספח 6.3.1 – בדיקת נכונות המודל	30
1. נבדקי הדרייב אין	30
2. נבדקי מד"א	32
3. קופות החולים	33
נספח 6.3.2 – ערכי המדדים עבור המצב הקיים	34
נספח 6.4.1 – ערכי המדדים עבור חלופה 1	34
נספח 6.4.2 – ערכי המדדים עבור חלופה 2	34
נספח 6.5.1 – מבחני t מזווג להשוואת חלופות	35



3. תקציר

בפרויקט זה נבחן את מערך בדיקות הקורונה של מדינת ישראל, נכון לחודש אוקטובר 2020. מטרת הפרויקט הינה לבצע סימולציה ומידול של המצב הקיים, בחינת ערכי המדדים הקריטיים שבחרנו לטובת בחירת חלופות שונות למערך הקיים לטובת שיפורו. על כן, עמד לרשותנו תקשיב של 3,000,000 ₪ לכל חלופה. את המדדים בחרנו בהתאם למטרות הארגון – לבצע מקסימום בדיקות בזמן הקצר ביותר, מתן מענה מהיר לאנשים עם סימפטומים שמצבם הבריאותי אינו תקין ולספק תשובות לנבדקים בהקדם האפשרי על מנת להקטין את קצב ההדבקה. המדדים שבחרנו הינם: **אורך התור הממוצע למערך האמבולנסים של מד"א ולמעבדת מרכז**, שהייתה העמוסה ביותר, **וזמן ההמתנה הממוצע לקופות החולים**. את מדדים אלו רצינו למזער כדי לשפר את יעילות ואיכות השירות. במצב הקיים קיבלנו כי אורך התור הממוצע למערך האמבולנסים של מד"א היה **8.766 נבדקים**, זמן ההמתנה הממוצע לקופות החולים היה **22.265 דקות**, ואורך התור הממוצע למעבדת מרכז היה **141.805 בדיקות**. על מנת לשפר את ערכי המדדים הצענו 2 חלופות: **בחלופה הראשונה** בחרנו להוסיף אמבולנס נוסף למערך של מד"א, השתלמות לעובדי המערך לטובת קיצור זמן הבדיקה לדקה אחת והגדלת כוח האדם במעבדות באמצעות הוספת עמדה נוספת לאחת המעבדות. **בחלופה השנייה** בחרנו לשדרג את צי האמבולנסים הקיים לטובת קיצור כלל זמני הנסיעה. לאחר בחינה והשוואה בין החלופות לפי המדדים בעזרת מבחן t מזווג **נמליץ למערך בדיקות הקורונה את החלופה הראשונה**, מאחר והיא גורמת לשיפור בכל המדדים. אורך התור הממוצע למערך האמבולנסים של מד"א הצטמצם ל-**7.226 נבדקים**, זמן ההמתנה הממוצע לקופות החולים קטן בצורה משמעותית והפך ל-**2.891 דקות**, ואורך התור הממוצע למעבדת מרכז הצטמצם ל-**123.040 בדיקות**. לסיכום, התקציב שקיבלנו, באמצעות השקעה בחלופות שהצענו, יוכל לשפר את מערך הבדיקות בהתאם למטרות הארגון ולהביא להצלחה גדולה יותר במלחמה נגד נגיף הקורונה במדינת ישראל.

4. מבוא

4.1 תיאור המערכת הנחקרת

המערכת אותה אנו חוקרים בפרויקט כוללת מערך בדיקות קורונה הפועל ללא הפסקה, ומתחלק על לפי 3 אזורים: צפון הארץ, דרום הארץ ומרכז. מערך הבדיקות כולל **מתחמי דרייב-אין** אליהם מגיעים אזרחים להיבדק במידה ואינם שוהים בבידוד וללא צורך בהפניה מרופא, **קופות החולים** המספקות בדיקות דחופים לאלו אשר ניתנה האפשרות לקבלת בדיקה מהירה (אנשי עסקים, נבחרי ציבור וספורטאים לפני טיסות לחו"ל) **ואנשי מד"א** המגיעים לבית הנבדקים עליהם אסורה היציאה מהבית (**נספח 4.1.1**). ישנם 3 מתחמי **מגה דרייב-אין** המפוזרים בחלקי הארץ, אחד לכל אזור. מתחמי הדרייב-אין פועלים בין השעות 06:00-21:00. כל מתחם כזה מכיל מספר מתחמי מיני דרייב-אין (3 לצפון ולדרום, 4 למרכז), כשבכל מתחם מיני פועלות 3 עמדות בדיקה במקביל (**נספח 4.1.2**). בשעה 18:00 נסגרת אחת מעמדות הבדיקה בכל מתחם. לאחר הסגירה, אנשים שהגיעו לבצע בדיקה לפני שעת הסגירה, יבצעו את הבדיקה ורק לאחר מכן ילכו לביתם. הדגימות נאספות כל 4 שעות ומועברות



למעבדות לבדיקה. במידה ובמגה דרייב-אין מצטברת קופסת בדיקות הכוללת 100 בדיקות, היא נשלחת מיידית למעבדה. מערך **קופות החולים** כולל 15 עמדות לבדיקה המפוזרות ברחבי הארץ, 4 בצפון ובדרום ו-7 במרכז. העמדות פתוחות כל יום בין השעות 9:00-13:00 ו-14:00-18:00 (נספח 4.1.3). לאחר סגירת העמדה, האנשים שהספיקו להגיע לפני שעת הסגירה יבצעו את הבדיקה לפני שיעזבו. הבדיקות בקופות החולים נבדקות במקום על מנת לספק תשובה מהירה לנבדקים. **מעריך האמבולנסים של מד"א** פועל 24/7 וכולל 20 אמבולנסים המסתובבים ברחבי הארץ. תפקיד מעריך האמבולנסים הוא להגיע אל בתי הנבדקים ולבצע את הבדיקה, תוך הודעה לנבדק כי האמבולנס בדרך אליו. בזמן איסוף הבדיקות, צוותי מד"א אינם זמינים לבדיקת אנשים בביתם עד אשר פורקים את הבדיקות במעבדות ואוספים ציוד חדש להמשך העבודה (נספח 4.1.4). **מעריך המעבדות** כולל 3 מעבדות, אחת לכל אזור בארץ. בכל עמדה קיימות 20 עמדות בדיקה מקבילות (נספח 4.1.5). המעבדות נותנות עדיפות לבדיקות המגיעות מקופות החולים ומוגדרות כבדיקות דחופות יותר. לאחר פיענוח כל בדיקה, התשובה מועברת היישר לנבדק. הבדיקה יכולה להיות חיובית, שלילית או גבולית (נספח 4.1.6). אם **הבדיקה חיובית**, על הנבדק להיכנס לבידוד, ובעקבותיו 2 אנשים צריכים לבצע בדיקת קורונה במתחם הדרייב-אין, שכן שם יבצעו את הבדיקה דרך רכבם ולא יצטרכו לבוא במגע עם אנשים נוספים. אם **הבדיקה גבולית**, על הנבדק לבצע בדיקה נוספת באותו האופן בו בוצעה בדיקתו הקודמת. אם הבדיקה מתגלה כגבולית בפעם השנייה, היא נחשבת כחיובית. אם **הבדיקה שלילית**, הנבדק כמובן אינו חולה בקורונה. על מנת לנהל את מעריך הקורונה כך שיוכל לספק שירותים לכלל האוכלוסייה במדינה, המתחמים השונים צריכים לתת מענה זמין ומהיר, במינימום זמני המתנה בתורים ולמנוע קירבה שלא כצורך בין אנשים. בנוסף, מעריך הבדיקות צריך להיות יעיל ככל הניתן על מנת להחזיר תשובה מהירה לנבדקים ולמנוע הדבקה של אנשים אחרים. כמו כן, נרצה למנוע מהעובדים המסורים של מעריך הבדיקות שחיקה מיותרת, ושיוכלו ללכת לביתם בשעות סבירות לקראת יום עבודה חשוב למחרת.

4.2 מטרות

מטרת הארגון – הארגון המתואר הינו משרד הבריאות בשיתוף עם קופות החולים. המטרה העיקרית בשילובם הינה להקים מערך יעיל ככל הניתן על מנת לבצע מקסימום בדיקות בזמן הקצר ביותר, מתן מענה מהיר לאנשים עם סימפטומים שמצבם הבריאותי אינו תקין ולספק תשובות בהקדם האפשרי על מנת להקטין את קצב ההדבקה, כל זאת תוך שמירה על המגבלות השונות עקב המצב.

מטרת הסימולציה – בחינה מעמיקה של מעריך הבדיקות הקיים. בחינה זו כוללת הרצת מודל על פי הנתונים הקיימים, על מנת לבחון את אורכי התורים ונצילות המערכת. מכאן, בחירת המדדים הקריטיים לבחינת חלופות אפשריות לשיפור המעריך.

מטרת הפרויקט – בשלב ראשון, מידול והבנה מעמיקה של המצב הקיים, בחינת הנתונים וזיהוי מוקדים בעייתיים לטובת בחירת מדדים לניתוח ופתרון הבעיה. בשלב השני, שימוש בכלים סטטיסטיים לניתוח החלופות האפשריות בהתאם למגבלות התקציב, על מנת למצוא את החלופה הכדאית בהתאם למדדים שנבחרו.



5. מודל הסימולציה

5.1 תיאור המודל

את בניית המודל ביצענו באמצעות תוכנת ה-R Studio תוך שימוש בחבילת Simmer. על מנת למדל את מערך בדיקות הקורונה יצרנו ישויות (נספח 5.1.1 , נספח 5.1.9), משאבים (נספח 5.1.12) ומסלולים מתאימים. את התפלגות זמני ההגעה של הלקוחות השונים, הלקוחות שמגיעים למתחמי הנה (נספח 5.1.10) והלקוחות בעלי הסימפטומים שפונים לאנשי מד"א (נספח 5.1.11), חישובנו באמצעות ה-R.Markdown. את התפלגויות זמני ההגעה מצאנו על ידי חישוב ראשוני של קצבי ההגעה, התבוננות בגרפים התואמים לנתונים וביצועי מבחני טיב התאמה עד למציאת ההתפלגות המתאימה. התחלת הסימולציה בשעה 00:00 כלומר בתחילתו של יום חדש ונגמרת 48 שעות לאחר מכן. לטובת הסימולציה, התייחסנו אל הישויות השונות כבדיקות, כלומר בהתחלה הישות היא לקוח ולאחר מכן היא מתוארת כבדיקה.

מסלול בדיקת הקורונה הראשי של לקוחות ה-Drive-In (נספח 5.1.2): למסלול זה מגיעים הלקוחות אשר אמורים להיבדק במתחמי Drive-In השונים ברחבי הארץ. כל אחד מהלקוחות שמגיעים מתפזרים ל- Mega-Drive-In המתאימים להם לפי מיקומם בארץ (35% למגה מתחם הצפוני, 42% למגה מתחם המרכזי ו-23% למגה מתחם הדרומי).

מסלול מתחם מגה Drive-In (נספח 5.1.3): כאשר ישות מגיעה למסלול זה, היא נכנסת למגה מתחם ובוחרת ללכת לאחד מהמיני מתחמים בתוכו. הבחירה נעשית לפי אורך התור הקצר ביותר מבין כלל התורים. לאחר מכן אותה ישות תופסת את המשאב שאמור לתת לה את השירות המבוקש ועוברת את בדיקת הקורונה. הבדיקה עצמה נאגרת במגה מתחם עד אשר הצטברו 100 בדיקות או שעברו 4 שעות מזמן ביצוע הבדיקה הראשונה. כאשר אחד התנאים שהוזכרו לעיל מתקיימים, הבדיקות מועברות על פי הקרבה הגיאוגרפית למעבדה המתאימה ושם נבדקות. ברגע שהתקבלו התוצאות עבור בדיקה מסוימת, הבדיקה (הישות) תנותב לאחד מתת המסלולים הסופיים.

מסלול בדיקת קורונה ראשי של קופות החולים (נספח 5.1.5): למסלול ראשי זה מגיעים לקוחות אשר אמורים להיבדק בדחיפות באחת מקופות החולים. כל אחת מהישויות שמגיעות למסלול מתפזרות לקופת החולים המתאימה על פי המיקום הגיאוגרפי (35% למגה מתחם הצפוני, 42% למגה מתחם המרכזי ו-23% למגה מתחם הדרומי).

מסלול קופת חולים (נספח 5.1.6): כאשר לקוח מגיע לקופת החולים, הוא תופס את המשאב לפי השירות המבוקש. כאשר אחד המשאבים נתפס על ידי הישות, המשאב מבצע את בדיקת הקורונה ולאחר מכן מעביר את הבדיקה למעבדה הסמוכה (לפי המיקום הגיאוגרפי). באותה מעבדה מתקבלות תוצאות הבדיקה, ולאחר מכן כל בדיקה (ישות) מנותבת לאחד מתת המסלולים הסופיים המתאימים.

מסלול בדיקת קורונה על ידי אנשי מד"א (נספח 5.1.4): למסלול זה מגיעים נבדקים עם סימפטומים שקיבלו הפנייה מהרופא ואסור להם לצאת מביתם. ישות אשר נכנסת למסלול זה מנסה לתפוס את המשאב (אמבולנס). האמבולנס נוסע לביתו ומבצע את בדיקת הקורונה, ובסיומה, הבדיקה מאוחסנת באמבולנס. כעבור 4 שעות מרגע אחסון הבדיקה הראשונה מגיעים "מפקחי אמבולנס", תופסים את כל



משאבי האמבולנסים ולוקחים את הבדיקות למעבדות. האמבולנסים מפזרים את הבדיקות בין המעבדות בהתאם להסתברויות הבאות: בסיכוי 35% בדיקה מסוימת תועבר למעבדה הצפונית, בסיכוי 42% למעבדת מרכז וב-23% למעבדה הדרומית. כל בדיקה נבדקת במעבדה ובסופה מתקבלות התוצאות. בהתאם לתוצאות, אותה בדיקה (ישות) תנותב לאחד מתת המסלולים המתאימים.

מסלולי הבדיקה לאחר קבלת תוצאותיה: אלו הם בעצם מסלולי הסיום של הישויות (הבדיקות). לאחר שהתקבלו התוצאות של הבדיקות, כל בדיקה מנותבת לאחד המסלולים הבאים: אם תוצאת הבדיקה היא שלילית (בסיכוי 75%) הישות יוצאת מהמערכת, כלומר הולכת הביתה (נספח 5.1.7). אם תוצאת הבדיקה היא חיובית (בסיכוי 10%) הישות הולכת למסלול הבידוד ובו גורמת ליצירת שתי ישויות נוספות (נספח 5.1.8) שצריכות לעבור בדיקה. אחרת (בסיכוי 15%), הבדיקה יוצאת גבולית ולכן אותה ישות חוזרת לאותו מסלול בו היא ביצעה את הבדיקה ושם היא מבצעת בדיקה חוזרת. אם אותה ישות חוזרת פעם שניה למסלול של הבדיקות הגבוליות היא ישר מנותבת למסלול הבידוד. חשוב לציין, כי לבדיקות שמגיעות מקופות החולים ישנה חשיבות רבה יותר משאר הבדיקות שמגיעות למעבדות ולכן הם יועדפו על שאר הבדיקות (ביצוע עקיפה בתור).

5.2 הנחות

ההנחות לגבי המערכת הנחקרת עליהן מתבסס מודל הסימולציה:

- הישויות שמגיעות ל-Drive-In מגיעות רק בשעות הפעילות.
- האמבולנסים שולחים את הבדיקות למעבדות לפי אחוזי הנבדקים הנתונים.
- במצב שבו תחנות Drive-In נסגרות (21 בערב), המקום של הישות בתור נשמרת עד לשעה 6:00 ביום שלמחרת.
- לכל אמבולנס יש זמן נסיעה שונה למעבדות, אך תחילת פענוח הבדיקות בכל המעבדות מתחיל באותו הזמן (עד שאחרון האמבולנסים מגיע למעבדה).
- אלו שעומדים בתורים לקופות החולים בשעה 13:00 ממתינים בתור עד לפתיחה המחודשת של קופות החולים בשעה 14:00.
- 2 הישויות שנחשפו לחולה קורונה הולכות לבצע בדיקה במתחמי ה-Drive-in.
- כעבור 4 שעות בדיוק מקבלת הבדיקה הראשונה באמבולנסים, האמבולנסים מסיימים את הבדיקה הנוכחית ונוסעים למעבדות.
- ספירת ה-4 שעות לאיסוף הבדיקות ממתחמי ה-Drive-in וממד"א מתחיל עם קבלת הבדיקה הראשונה.
- ישויות שעשו בדיקה ב-Drive-In או בקופות החולים ונדרשו לבצע בדיקה שניה מכיוון שתוצאות הבדיקה גבוליות, יבצעו את הבדיקה השנייה באותו היום. לעומת זאת, אם ה-Drive-in סגור, הם יחכו עד לבוקר שלמחרת.



ההנחות לצורך הניתוח הסטטיסטי וחישוב המדדים

הנחנו כי קיימת תלות בין ריצות מקבילות בשתי הסדרות. בנוסף, לא קיימת תלות בין ריצות בכל חלופה באשר לעצמה. קיים שוויון שונויות בין הסדרות והתוצאות מתפלגות נורמלית. עבור מדדי הממוצעים (אורך תור ממוצע וזמן המתנה ממוצע), ידוע פילוג נורמלי על פי משפט הגבול המרכזי.

6. ניתוח מצב קיים והצעת חלופות

6.1 בחירת מדדים לניתוח

בהתאם לאופי הארגון ומטרות הפרויקט, ניתוח המצב הקיים ובחינת המודל, הגדרנו את המדדים הבאים:

אורך תור ממוצע במד"א – מערך האמבולנסים של מד"א הינו חלק אינטגרלי במערך הבדיקות. בהתאם לעלייה בקצב ההדבקה, גדלה גם כמות האנשים שנמצאים בבידוד וצריכים לבצע את הבדיקה בביתם. בעקבות חשיבותו של מערך האמבולנסים של מד"א וזמינותו ההכרחית לאנשים בעלי סימפטומים שנמצאים בסיכון גבוה, בחרנו לבחון את מדד זה (נספח 6.1.1). מדד זה מעיד על יעילות השירות, וככל שאורך התור הממוצע גדול יותר, כך יעילות השירות נמוכה יותר.

אורך תור ממוצע במעבדת מרכז – המעבדה במרכז הארץ הינה המעבדה העמוסה ביותר, לכן בחרנו לבחון מדד זה (נספח 6.1.2). יעילות המעבדות תורמת להחזרת תשובה מהירה לנבדקים לגבי תוצאות הבדיקה, וכך נבדקים אשר תוצאתם גבולית יוכלו לחזור לבדיקה נוספת בהקדם. בנוסף, כאשר נבדק יקבל את תוצאות הבדיקה מהר יותר, הוא יחל בתקופת הבידוד מוקדם יותר אם הבדיקה חיובית או ימשיך בחייו במידה והיא שלילית. מדד זה מעיד על יעילות השירות, וככל שאורך התור הממוצע גדול יותר, כך יעילות השירות נמוכה יותר.

זמן המתנה ממוצע בתור לקופות החולים – קופות החולים מבצעות בדיקות ומעבירים את הבדיקה למעבדה הקרובה במידה. זמן המתנה קצר מעיד על איכות ויעילות השירות. העומס בקופות החולים יחסית גבוה ולכן בחרנו להתמקד גם במדד זה (נספח 6.1.3).

חישוב המדדים:

חישוב אורך תור ממוצע – המשתנה Queue מייצג את מצב התור לעמדה מסוימת. ערך הממוצע חושב לפי הזמן שחלף מהרגע שלקוח הגיע לעמדה, עד לרגע קבלת השירות. כאשר זמן הסימולציה הוא T_{max} , חישוב הממוצע יהיה:

$$avg_{General Queue} = \frac{1}{T_{max}} \cdot \int_0^{T_{max}} GenralQueue(t) dt$$

חישוב זמן ההמתנה הממוצע – המשתנה start_time מגדיר את רגע כניסת הישות לקופת החולים, finished_HMO מגדיר את הרגע בו הישות יצאה מהבדיקה (אורכה 1.5 דקות). לכן חישוב זמן ההמתנה הממוצע חושב לפי:

$$AVG waiting time = finished_HMO - start_time - 1.5$$



6.2 סוג המערכת

המערכת אותה בחנו היא מערכת מסוג **Non Terminating System**, מכיוון שאין לנו תנאי לסיום הריצה, המערכת עובדת 24/7, ובנוסף הנבדקים והבדיקות מועברים מיום ליום. על כן, בחנו את זמן החימום של המערכת לפי המדדים שבחרנו, שיצא 21 ימים (נספח 6.2.1). יחידות הזמן שבמודל הוגדרו להיות בדקות. מכאן, משך זמן של הרצה בודדת יהיה פי 4 מזמן החימום, כלומר 84 ימים (120,960 דקות). לאחר זמן החימום המערכת יציבה והנתונים המתקבלים ממנה משקפים את המתרחש במציאות. על כן, את חישוב המדדים ביצענו לפי הנתונים שהתקבלו החל מנקודת סיום זמן החימום. בחרנו את מספר ההרצות הראשוני להיות $n_0 = 15$. עבור דיוק יחסי של $\gamma = 0.12$ ורמת מובהקות $\alpha_{total} = 0.1$ ביצענו את החישובים (נספח 6.2.2, נספח 6.2.3), אותם נרכז בטבלה הבאה:

ניתן לראות כי כל החלופות עומדות בדיוק היחסי ביחס לכל המדדים, לכן נקבע כי מספר הריצות $n = 15$.

6.3 ניתוח מצב קיים ביחס למדדים ולמטרות

לאחר בדיקת נכונות המודל (נספח 6.3.1) אלה הערכים שהתקבלו (נספח 6.3.2):

מדד	אורך תור ממוצע במד"א	זמן המתנה ממוצע בתור לקופות החולים	אורך תור ממוצע במעבדת מרכז
מצב קיים	0.0689 ✓	0.0130 ✓	0.0273 ✓
חלופה 1	0.0221 ✓	0.0043 ✓	0.0324 ✓
חלופה 2	0.1060 ✓	0.0124 ✓	0.0303 ✓

מדד אורך התור באמבולנסים של מד"א עומד על 8.766 נבדקים. מדד זה מציג לנו כי בזמן נתון ישנם כ-9 אנשים בתור לאמבולנס של מד"א. בחרנו לבחון מדד זה עקב חשיבותו הרבה – אנשים אשר יש להם סימפטומים נמצאים בסיכון הגבוה ביותר מבין הלקוחות הקיימים במערכת, ועליהם לקבל ביקור של צוות רפואי במהרה. מאחר וזמני הנסיעות משתנים תור של 9 אנשים יכול להגיע לזמן המתנה:

$$(10_{driving\ time} + 1.5_{testing\ time}) * 9 = 103.5_{minutes}$$

מאחר וזמן זה אינו מספיק טוב, ננסה למצוא חלופה אשר תצמצם את המדד.

מדד זמן ההמתנה הממוצע בקופות החולים עומד על 22.265 דקות. בשונה משאר התורים במערכת (במד"א המתנה ביתית, בדרייב-אין המתנה ברכב פרטי), זמן שהייה גבוה בקופת החולים יגרור חשיפה גבוהה יותר לאנשים חולים ולהתקהלויות אשר יכולות להגדיל את כמות הנדבקים.



בנוסף לכך, אנו מבינים כי קיימת חשיבות רבה ללקוחות קופות החולים עקב העדיפות בתהליך בדיקת המעבדה. לכן, נציע חלופות שיוכלו למזער את זמן ההמתנה שלהם ככל שניתן.

מדד אורך התור הממוצע במעבדה באזור המרכז עומד על 141.805 נבדקים. ככל שהתורים במעבדות גדולים יותר, כך תוצאות הבדיקה יאחרו להגיע. כמו שאנו יודעים, אם לא יגיעו הבדיקות במהירות האפשרית, אנשים שצריכים להיבדק ולהיכנס לבידוד יתעכבו וייתכן וידביקו אנשים נוספים בזמן זה. מאחר ומעבדת המרכז היא הגדולה והעמוסה ביחס לשאר המעבדות, זיהינו תור ממוצע של כ-142 בדיקות, אם נכפיל בזמן הבדיקה נקבל $5 \times 136 = 680$ דקות. זמן זה שווה ערך לכ-11 שעות המתנה לקבלת תשובה. מאחר והמעבדות אינן עובדות במהלך הלילה, מתן תוצאות הבדיקה יכול להתעכב אף יותר. על כן, מדד זה קריטי ועלינו לאתר חלופה שתמזער את התור.

6.4. תיאור החלופות

לטובת שיפור המצב הקיים במערך בדיקות הקורונה, הופקד בידנו תקציב של 3,000,000 ₪. נרצה להמליץ על שיפורים אפשריים בתקציב הנתון, בהתאם למטרות ולמדדים שבחרנו, אשר השפעתם תהיה המשמעותית ביותר לשיפור המערך הקיים. כחלק מהמטרות שהוגדרו לבצע מקסימום בדיקות בזמן הקצר ביותר, מתן מענה מהיר לאנשים עם סימפטומים שמצבם הבריאותי אינו תקין ולספק תשובות לנבדקים בהקדם האפשרי על מנת להקטין את קצב ההדבקה, בחרנו בחלופה הבאות:

חלופה ראשונה

חלופה	עלות (שנתית)
השתלמות עבור העובדים במערך הבדיקות – הקטנת זמן לקיחת דגימה	850,000 ₪
הגדלת כוח אדם באחת המעבדות – הוספת עמדה	1,250,000 ₪
הוספת אמבולנס למד"א	900,000 ₪

בחלופה זו, התייחסנו לתורים הארוכים לסירוגין שנוצרים למערך הבדיקות של מד"א ולדגימות שנאספות במעבדות. באמצעות הוספת אמבולנס נוסף, מד"א יהיו זמינים להגיע ללקוחות נוספים וכך נקטין את התור למשאב זה. כמו כן, בחרנו להוסיף עמדה נוספת למעבדה במרכז, לה היה את התורים הארוכים ביותר מבין המעבדות. הוספת העמדה תביא אף היא להקטנת התור במעבדה זו, כך תוצאות הבדיקה יגיעו מהר לנבדקים ומכאן תשפיע על המערך כולו. בנוסף, הקטנת זמן לקיחת הדגימה באמצעות השתלמות לעובדים בכלל המחלקות יוכל להביא להקטנת זמן השהייה הכולל של הישויות במערך כולו. כך, נוכל לצמצם את התורים במחלקות השונות שכן זמן השירות יהיה מהיר מהמצב הקיים. תוצאות המדדים לאחר מימוש השיפורים המוצעים בחלופה הראשונה (נספח 6.4.1):



מדד אורך תור ממוצע במד"א – ניתן לראות כי ממוצע המדד עומד על 7.226 והשתפר מאשר במצב הקיים, אשר עמד על 8.766. **מדד זמן המתנה ממוצע בתור לקופות החולים** – ניתן לראות שיפור משמעותי במדד זה וכעת עומד על 2.891, לעומת המצב הקיים בו המדד עמד על 22.265. **מדד אורך תור ממוצע במעבדת מרכז** – גם ממד זה השתפר ועומד על 123.040, לעומת המצב הקיים בו ערך המדד היה 141.805.

חלופה שנייה

חלופה	עלות (שנתית)
שדרוג צי האמבולנסים הקיים – הקטנת זמני הנסיעה	3,000,000 ₪

בחלופה זו, התייחסנו לתורים הארוכים שנוצרים למערך הבדיקות של מד"א. מבחינתנו, מערך זה הינו החשוב ביותר למערכת כולה, שכן הוא צריך לטפל באנשים בעלי סימפטומים, כלומר מצבם הבריאותי אינו תקין. בנוסף, כל 4 שעות המערך אינו זמין לנבדקים, בשונה משאר המתחמים שפועלים באופן רציף. מכאן, הקטנת זמני הנסיעה של המערך ישפיע על גודל התור משמעותית. לעומת זאת, אנו מניחים כי קיצור זמני הנסיעה ישפיעו על העומס בתורים למעבדות, שכן קצב הגעת הבדיקות למעבדות יגדל בעקבות שיפור זה. תוצאות המדדים לאחר מימוש השיפורים המוצעים בחלופה השנייה (נספח 6.4.2): **מדד אורך תור ממוצע במד"א** – ניתן לראות כי המדד עומד על 6.505, המהווה שיפור לעומת המצב הקיים שעמד על 8.766. **מדד זמן המתנה ממוצע בתור לקופות החולים** – ניתן לראות שיפור מינורי במדד זה העומד על 22.297, לעומת המצב הקיים בו המדד עמד על 22.265. **מדד אורך תור ממוצע במעבדת מרכז** – כפי שצפינו, ערך המדד הדרדר ועומד על 140.819, לעומת המצב הקיים בו ערך המדד היה 141.805.

6.5. השוואה סטטיסטית בין מצב קיים לחלופות מוצעות

לאחר בחינת המצב הקיים ושני החלופות שהצענו על פי שלושת המדדים, נרצה לבצע השוואות סטטיסטיות בין המצב הקיים לכל חלופה ובין החלופות עצמן, על מנת לבחון איזו חלופה אופטימלית. לשם כך, ביצענו מבחן t מזווג ל-9 השוואות שונות – עבור כל מדד ובין כל חלופה (נספח 6.5), ברמת מובהקות שחושבה לפי: $\alpha_i = \frac{\alpha_{total} = 0.1}{9} = 0.011$ כאשר α_{total} הינה רמת המובהקות הכללית. N הינו מספר ההשוואות שביצענו. בחרנו לבצע שימוש במבחן t מזווג בהתאם לקיום ההנחות הבאות:

- יש תלות בין ריצות מקבילות בשתי הסדרות (set.seed זהה להרצה i בכל חלופה).
- אין תלות בין ריצות בכל חלופה בפני עצמה (set.seed שונה בכל הרצה בחלופה מסוימת).
- נניח שוויון שוניות בין הסדרות.
- התוצאות מתפלגות נורמאלית (המדדים מדברים על ממוצע, המתפלג נורמאלי).

נצבע רווח סמך בין כל השוואה, לכל מדד, ובבחינת איזו חלופה עדיפה בטבלה הבאה (נספח 6.5.1):



אנו רואים כי עבור המדדים **זמן המתנה ממוצע בתור לקופות החולים**, **אורך תור ממוצע במעבדת מרכז נמליץ על חלופה 1**, ועבור מדד **אורך תור ממוצע במד"א** נמליץ על חלופה 1 או על חלופה 2.

מדד	השוואה	רווח סמך	תוצאות המבחן	חלופה מועדפת
אורך תור ממוצע במד"א	מצב קיים – חלופה 1	(0.499 , 2.4494)	חלופה 1	חלופה 1 / חלופה 2
	מצב קיים – חלופה 2	(0.773 , 3.654)	חלופה 2	
	חלופה 1 – חלופה 2	(-0.236 , 1.715)	אדישות	
זמן המתנה ממוצע בתור לקופות החולים	מצב קיים – חלופה 1	(19.150 , 19.770)	חלופה 1	חלופה 1
	מצב קיים – חלופה 2	(-0.277 , 0.367)	אדישות	
	חלופה 1 – חלופה 2	(-19.756 , -19.074)	חלופה 1	
אורך תור ממוצע במעבדת מרכז	מצב קיים – חלופה 1	(2.925 , 27.990)	חלופה 1	חלופה 1
	מצב קיים – חלופה 2	(-14.227 , 4.162)	אדישות	
	חלופה 1 – חלופה 2	(-27.476 , -13.503)	חלופה 1	

7. מסקנות

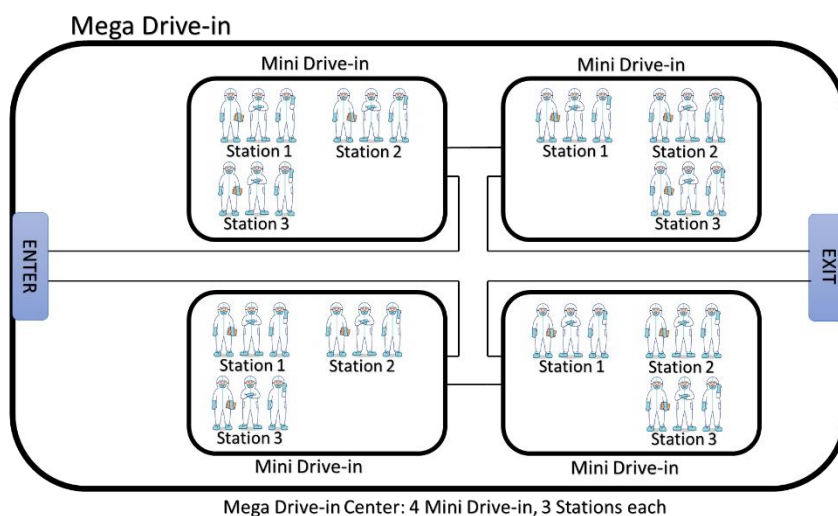
בפרויקט נבחנו מספר מדדים המהווים את שיקוף המצב הקיים בארגון ולעמידה במטרות שהציב לעצמו, וכן גם נבחנו חלופות אשר יועדו לשפר את המצב הקיים, תוך שימוש במידול איכותי של המערכת כך שהיא מייצגת בצורה מהימנה את המציאות. התוצאות שהתקבלו בסימולציה מראות כי המדדים **זמן המתנה ממוצע בתור לקופות החולים**, **אורך תור ממוצע במעבדת מרכז** אכן שופרו במובהקות גבוהה. מטרתנו הייתה למזער מדדים אלו וניתן לראות כי החלופות שהוצעו עבורם טובות מהמצב הקיים. הראנו כי **החלופה הראשונה הינה החלופה המיטבית עליה נמליץ לארגון**, אשר מביאה לשיפור וייעול המערכת כולה, ועומדת בתקציב הנתון. מכאן, השתלמות עבור העובדים במערך הבדיקות, הגדלת כוח אדם במעבדות והוספת אמבולנס, לא רק ישפרו את המדדים שנבדקו אלא את כלל המערכת הנבדקת ויעילותה. מאחר ובוצע סינון רעשים על ידי זמן חימום, ובנוסף 15 הרצות למצב הקיים, לחלופות שהוצעו ומובהקות התוצאות, אנו מאמינים כי ניתן להסתמך על המודל בקבלת ההחלטה הנדונה. המודל הנתון מציג את המצב הקיים והחלופות לאחר **המערכת התייצבה**, מכך אנו מסיקים כי הנתונים אמינים ומייצגים תמונה קרובה למציאות בהתאם לנתונים שקיבלנו. ניתן לראות כי בעת הגדרת סדר עדיפויות, גם חלופה 2 תהיה עדיפה, שכן חלופה זו משדרגת את צי האמבולנסים הקיים. במהלך הדו"ח הצגנו את חשיבות מד"א כמשאב זמין בזמן הקורונה, ואם אכן בעת קביעת סדר העדיפויות מדד זה יהיה קריטי, נמליץ לבחור בחלופה 2, גם היא עומדת בתקציב הנתון. לסיכום, נאמר כי **מטרות הפרויקט בהמשך למטרות הארגון והמערכת הושגו במידה מספקת**.

8. נספחים:


נספח 4.1.1 – קצב הגעה וזמן בדיקת קורונה

זמן (דקות / התפלגות)	פעולה
Exp (0.557)	קצב הגעת נבדקים לדרייב-אין
Exp (0.463)	קצב הגעת נבדקים עם סימפטומים (מד"א)
Exp (8)	קצב הגעת נבדקים לקופות החולים
1.5 דקות	זמן ביצוע בדיקת קורונה

נספח 4.1.2 – מבנה הדרייב-אין



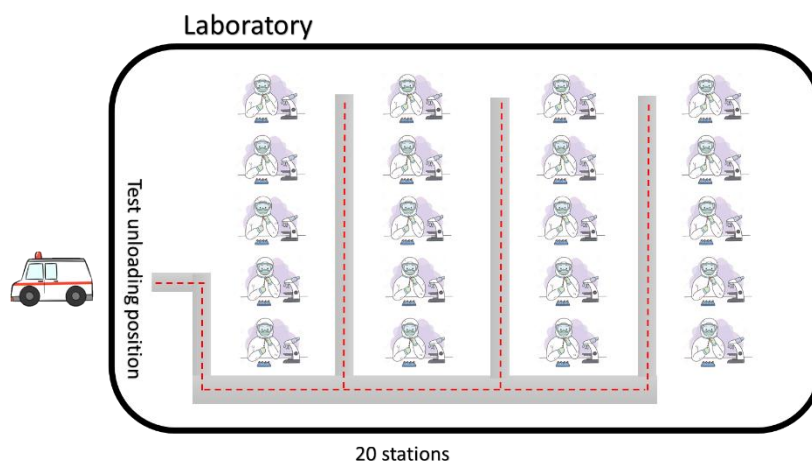
נספח 4.1.3 – פריסת קופות החולים



נספח 4.1.4 – זמני נסיעות והעברת בדיקות

פעולה	זמן (דקות / התפלגות)
זמן נסיעה אנשי מד"א לבית הנבדק	Triangle (10,20,15)
זמן נסיעה אנשי מד"א למעבדות	Norm (15,5)
זמן נסיעה מהדרייב-אין למעבדות	Norm (15,5)
זמן העברת בדיקה מקופות החולים למעבדות	Norm (15,5)
זמן להעברת הבדיקה למעבדה	10 דקות
זמן לקבלת ציוד חדש	10 דקות

נספח 4.1.5 – מבנה המעבדה



נספח 4.1.6 – זמן פענוח הבדיקה והתפלגות התוצאות

פעולה	זמן (דקות / התפלגות)
זמן פענוח בדיקה	5 דקות
התפלגות תוצאות הבדיקה	$f(x) = \begin{cases} negative, & 0.75 \\ inconclusive, & 0.15 \\ positive, & 0.1 \end{cases}$



נספח 5.1.1 – מחולל הישויות

הישויות נוצרות על פי ההתפלגויות הנתונות:

```
Covid19%>%
  add_generator("Drivein_clients",CovidTest,distribution= from_to(start_time = 6*60,stop_time = 21*60,function () rexp (1,0.557),FALSE, every = 24*60),mon=2,priority = 0,preemptible = 1,restart = TRUE)%>%
  add_generator("MDA_Clients", MDA, function () rexp (1,0.463), mon=2,priority = 0,preemptible = 1 ,restart = TRUE)%>%
  add_generator("HMO_Morning_Clients",HMO, distribution= from_to(start_time = 9*60 ,stop_time=13*60 , function () rexp (1,8),TRUE, every = 24*60), mon = 2,priority = 1,preemptible = 2 ,restart = TRUE)%>%
  add_generator("HMO_Noon_Clients",HMO, distribution= from_to(start_time = 14*60 ,stop_time=18*60 , function () rexp (1,8),TRUE, every = 24*60), mon = 2,priority = 1,preemptible = 2 ,restart = TRUE)%>%
  add_generator("DriveIn_quarantine", CovidTest, when_activated(2), mon=2,priority = 0,preemptible = 1 ,restart = TRUE)%>% ##generates 2 more people that need to get covid test
  add_generator("MDA_Supervisor", MDA_Break, when_activated(20), mon=2,priority = 2,preemptible = 3 ,restart = TRUE) ##generate 20 supervisors that take the ambulance to his break ####
```

כל אחת מן הישויות השונות הולכת למסלול המתאים לה:

נספח 5.1.2 – מסלול CovidTest

ישות Drivein_clients הולכת למסלול ה-CovidTest שם היא מקבלת את תכונת ה-VIP שערכה הוא אפס מכיוון והיא לא ישות VIP , ולאחר מכן נשלחת למתחם Mega Drive-In בהתאם למיקומה הגיאוגרפי (בסיכוי של 35% הישות מגיעה מדרום הארץ ולכן הולכת ל Mega Drive-In הדרומי, בסיכוי של 42% הישות מגיעה ממרכז הארץ ולכן הולכת ל Mega Drive-In המרכזי ובסיכוי של 23% הישות מגיעה מצפון הארץ ולכן הולכת ל Mega Drive-In הצפוני).

```
CovidTest <- trajectory("CovidTest")%>%
  set_attribute("VIP",0)%>%
  branch(option= function() rdiscrete(1,c(0.35,0.42,0.23),c(1,2,3)), continue=c(FALSE,FALSE,FALSE), N_mega_drivein, C_mega_drivein, S_mega_drivein)
```

נספח 5.1.3 – מסלול Mega Drive-In

כאשר הישות מגיעה Mega Drive-In המתאים, היא ראשית מקבלת תכונה Area עם הערך המשקף את האזור בארץ שבה היא מבצעת את הבדיקה (1-צפון, 2- מרכז, 3- דרום). המסלול שישות עוברת במגה מתחם: כולל עמידה בתור ← ביצוע הבדיקה←אחסון הבדיקה (המתנה)←שליחת הבדיקה למעבדה←קבלת תוצאת הבדיקה←שליחה למסלול הסופי המתאים.

```
N_mega_drivein <- trajectory("N_mega_drivein")%>% ##North drive-in traj
  set_attribute("Area",1)%>%
  simmer::select(resources=c("N1_mini_drivein", "N2_mini_drivein", "N3_mini_drivein"),policy=c("shortest-queue"))%>%
  seize_selected(amount = 1)%>%
  timeout(1.5)%>% ## Corona test time
  release_selected(amount = 1)%>%
  batch(100, timeout = 4*60, permanent = FALSE)%>% ## waiting batch, either 100 tests pending for result or 4 hour
  timeout(function () trimmedNorm(15,5))%>% ##time from drive-in to labs
  separate()%>%
  addService("Lab_N",5)%>% ##Lab test
  branch(option= function() rdiscrete(1,c(0.15,0.75,0.1),c(0,1,2)), continue=c(FALSE,FALSE),goHome,quarantine)%>% #
  rollback(11,1)%>% ##Go back and repeat the Corona test.
  leave(1,quarantine)
```

```
C_mega_drivein <- trajectory("C_mega_drivein")%>%
  set_attribute("Area",2)%>%
  simmer::select(resources=c("C1_mini_drivein", "C2_mini_drivein", "C3_mini_drivein", "C4_mini_drivein"),policy=c("shortest-queue"))%>%
  seize_selected(amount = 1)%>%
  timeout(1.5)%>%
  release_selected(amount = 1)%>%
  batch(100, timeout = 4*60, permanent = FALSE)%>%
  timeout(function () trimmedNorm(15,5))%>% ##time from drive in to labs
  separate()%>%
  addService("Lab_C",5)%>%
  branch(option= function() rdiscrete(1,c(0.15,0.75,0.1),c(0,1,2)), continue=c(FALSE,FALSE),goHome,quarantine)%>% ##Based on the pr
  rollback(11,1)%>% ##Go back and repeat the Corona test.
  leave(1,quarantine)
```



```
S_mega_drivein <- trajectory("S_mega_drivein")%>%
  set_attribute("Area",3)%>%
  simmer::select(resources=c("S1_mini_drivein","S2_mini_drivein","S3_mini_drivein"),policy=c("shortest-queue"))%>%
  seize_selected(amount = 1) %>%
  timeout(1.5) %>%
  release_selected(amount = 1)%>%
  batch(100, timeout = 4*60, permanent = FALSE) %>%
  timeout(function () trimmedNorm(15,5))%>% ##time from drive in to labs
  separate()%>%
  addService("Lab_S",5)%>%
  branch(option= function() rdiscrete(1,c(0.15,0.75,0.1),c(0,1,2)), continue=c(FALSE,FALSE),goHome,quarantine)%>%
  rollback(11,1)%>% ##Go back and repeat the Corona test.
  leave(1,quarantine)
```

נספח 5.1.4 – מסלול MDA

ישות ה-MDA_clients הולכת למסלול MDA שם היא מקבלת את התכונה Symptoms כיוון ומי שהולך למסלול זה אלו ישויות עם סימפטומים שאסור להם לצאת מהבית. בנוסף ברגע שאמבולנס יוצא לכיוון הישות(תפיסת המשאב), הישות מקבלת תכונת onTheWay המעדכנת כי אחד האמבולנסים בדרך אליה. המסלול שהישות עוברת במסלול זה :

תפיסת אמבולנס ← ביצוע בדיקת קורונה ← אחסון הבדיקה (המתנה) ← העברת הבדיקה ע"י "מפקחי האמבולנס" (המתנה של זמן הנסיעה למעבדות) ← מעבר למסלול המעבדות לצורך בדיקה ← קבלת תוצאת הבדיקה ← שליחה למסלול הסופי המתאים.

```
MDA <- trajectory("MDA")%>%
  set_attribute("Symptoms",1)%>%
  seize(resource = "MDA",amount=1)%>%
  set_attribute("onTheWay",1)%>%
  timeout(function() rtriangle(1,10,20,15) + 1.5)%>% ##the time it takes to drive to the client and test him for corona
  release("MDA", amount =1)%>%
  batch( 10000, timeout = 4*60, permanent = FALSE)%>%
  deactivate(sources = "MDA_Supervisor")%>%
  activate(sources = "MDA_Supervisor")%>% #activate supervisor generator
  seize(resource = "MDA",amount = 20)%>% #the batch wait for the ambulances to reach the lab
  timeout(0)%>%
  release("MDA", amount = 20)%>%
  separate()%>%
  branch(option= function() rdiscrete(1,c(0.35,0.42,0.23),c(1,2,3)), continue=c(TRUE,TRUE,TRUE),Lab_North_Traj,Lab_Center_Traj,Lab_South_Traj)%>%
  branch(option= function() rdiscrete(1,c(0.15,0.75,0.1),c(0,1,2)), continue=c(FALSE,FALSE),goHome,quarantine)%>% ##Based on the probability we send the entities as instructed
  rollback(15,1)%>% ##Go back and repeat the Corona test.
  leave(1,quarantine)
```

```
Lab_North_Traj <- trajectory("Lab_North_Traj")%>%
  addService("Lab_N",5)

Lab_Center_Traj <- trajectory("Lab_Center_Traj")%>%
  addService("Lab_C",5)

Lab_South_Traj <- trajectory("Lab_South_Traj")%>%
  addService("Lab_S",5)
```

נספח 5.1.5 – מסלול קופת חולים ראשי

ישות ה-HMO_Morning_Clients או ישות HMO_Noon_Clients הולכות למסלול HMO שם הן מקבלות את תכונת ה-VIP שערכה הוא 1 מכיוון והן ישויות VIP כלומר הן צריכות לעשות בדיקות בדחיפות, ולאחר מכן נשלחות לקופת חולים לצורך בדיקה בהתאם למיקומם הגיאוגרפי (בסיכוי של 35% הישות מגיעה מדרום הארץ ולכן הולכת לקופת חולים הדרומית, בסיכוי של 42% הישות מגיעה ממרכז הארץ ולכן הולכת לקופת חולים במרכז ובסיכוי של 23% הישות מגיעה מצפון הארץ ולכן הולכת לקופת חולים הצפונית).

```
HMO <- trajectory("HMO")%>%
  set_attribute("VIP",1)%>%
  branch(option= function() rdiscrete(1,c(0.35,0.42,0.23),c(1,2,3)), continue=c(FALSE,FALSE,FALSE), N_HMO, C_HMO, S_HMO)
```




נספח 5.1.6 – מסלול שהישות עוברת בקופת חולים

כאשר הישות מגיעה לקופת חולים, היא מקבלת תכונה Area עם הערך המשקף את האזור בארץ שבה היא מבצעת את הבדיקה (1-צפון, 2-מרכז, 3-דרום), ובנוסף מקבלת תכונת finished_hmo המעדכנת מתי אותה ישות סיימה את שהותה בקופת חולים ועוברת למעבדה. המסלול שישות עוברת בקופת חולים: עמידה בתור → ביצוע הבדיקה → העברת הבדיקה למעבדה הקרובה (המתנה) → קבלת תוצאת הבדיקה → שליחה למסלול הסופי המתאים.

```
N_HMO <- trajectory("N_HMO")%>%
  set_attribute("Area",1)%>%
  seize("HMO_N",1)%>%
  timeout(1.5)%>%
  release("HMO_N",1)%>%
  set_attribute(key= "finished_hmo",1)%>%
  timeout(function () trimmedNorm(15,5))%>% ##time to transfer the test to the labs
  addService("Lab_N",5)%>% ##Lab test
  branch(option= function() rdiscrete(1,c(0.15,0.75,0.1),c(0,1,2)), continue=c(FALSE,FALSE),goHome,quarantine)%>%
  rollback(9,1)%>% ##Go back and repeat the Corona test.
  leave(1,quarantine)
```

```
C_HMO <- trajectory("C_HMO")%>%
  set_attribute("Area",2)%>%
  seize("HMO_C",1)%>%
  timeout(1.5)%>%
  release("HMO_C",1)%>%
  set_attribute(key= "finished_hmo",1)%>%
  timeout(function () trimmedNorm(15,5))%>%
  addService("Lab_C",5)%>%
  branch(option= function() rdiscrete(1,c(0.15,0.75,0.1),c(0,1,2)), continue=c(FALSE,FALSE),goHome,quarantine)%>%
  rollback(9,1)%>% ##Go back and repeat the Corona test.
  leave(1,quarantine)
```

```
S_HMO <- trajectory("S_HMO")%>%
  set_attribute("Area",3)%>%
  seize("HMO_S",1)%>%
  timeout(1.5)%>%
  release("HMO_S",1)%>%
  set_attribute(key= "finished_hmo",1)%>%
  timeout(function () trimmedNorm(15,5))%>%
  addService("Lab_S",5)%>%
  branch(option= function() rdiscrete(1,c(0.15,0.75,0.1),c(0,1,2)), continue=c(FALSE,FALSE),goHome,quarantine)%>%
  rollback(9,1)%>% ##Go back and repeat the Corona test.
  leave(1,quarantine)
```

נספח 5.1.7 – מסלול עזיבת המערכת

כאשר הישות מקבלת את תוצאת הבדיקה שלה והיא שלילית היא יוצאת מהמערכת והולכת הביתה.

```
goHome <- trajectory("goHome")%>% ##Leave trajectory
  set_attribute("positive", 0)
```

נספח 5.1.8 – מסלול הבידוד

כאשר הישות מקבלת את תוצאת הבדיקה שלה והיא חיובית, הישות מקבלת תכונה של Positive, גורמת ליצירת שתי ישויות נוספות ששהו בקרבתה ונכנסת לבידוד בבית.

```
quarantine <- trajectory("quarantine")%>%
  set_attribute("positive", 1)%>%
  deactivate(sources = "MDA_quarantine")%>%
  activate(sources = "MDA_quarantine")
```



כאשר הישות מקבלת את תוצאת הבדיקה שלה והבדיקה יוצאת גבולית, היא חוזרת לאותו מסלול שהיא עברה ועוברת אותו עוד הפעם לצורך בדיקה חוזרת (באמצעות שימוש בrollback בכל אחד ממסלולי הבדיקה השונים). כשאותה ישות מקבלת את תוצאות הבדיקה השנייה, אם היא שלילית היא הולכת הביתה ואם היא חיובית היא הולכת לבידוד (למסלולים המוצגים למעלה).

נספח 5.1.9 – הישיות השונות במערכת:

1. DriveIn_Clients – הישיות שמבצעות את בדיקת הקורונה במסלולי המגה Drive-in. קצב הגעת הישיות הינו $\text{Exp}(0.557)$.

```
add_generator("Drivein_Clients", CovidTest, distribution = from_to(start_time = 6*60, stop_time = 21*60, function () rexp (1,0.557),FALSE, every = 24*60), mon=2, priority = 0,preemptible = 1, restart = TRUE)
```

2. MDA_Clients – הישיות שמבצעות את בדיקת הקורונה באמבולנסים (אצל מד"א). קצב

```
add_generator("MDA_Clients", MDA, function () rexp (1,0.463), mon=2,priority = 0,preemptible = 1, restart = TRUE)
```

הגעת הישיות הינו $\text{Exp}(0.463)$.

3. HMO_Morning_Clients – הישיות שמגיעות לקופות החולים השונות לצורך ביצוע בדיקה

דחופה בשעות הבוקר מהשעה 9:00 בבוקר עד 13:00. קצב הגעת הישיות הינו $\text{Exp}(8)$.

4. HMO_Noon_Clients – הישיות שמגיעות לקופות החולים השונות לצורך ביצוע בדיקה

```
add_generator("HMO_Morning_Clients",HMO, distribution= from_to(start_time = 9*60, stop_time=13*60, function () rexp (1,8),TRUE, every = 24*60), mon = 2,priority = 1,preemptible = 2, restart = TRUE)
```

דחופה בשעות הצהריים מהשעה 14:00 בבוקר עד 18:00. קצב הגעת הישיות הינו $\text{Exp}(8)$.

```
add_generator("HMO_Noon_Clients",HMO, distribution= from_to(start_time = 14*60, stop_time=18*60, function () rexp (1,8),TRUE, every = 24*60), mon = 2,priority = 1,preemptible = 2, restart = TRUE)
```

5. MDA_quarantine – הישיות שנוצרות כתוצאה מכך שהיו בסביבת ישות חולה ועליהם

לבצע בדיקת קורונה ב-Drive-In.

```
add_generator("MDA_quarantine", MDA, when_activated(2), mon=2,priority = 0,preemptible = 1, restart = TRUE)
```

6. MDA_Supervisor – מפקחי האמבולנסים שנוצרים כל ארבע שעות ולוקחים את

האמבולנסים למעבדות לצורך העברת הבדיקות. לישיות אלו יש עדיפות גבוהה משאר

הישיות שהולכות למד"א כיוון והם צריכים לעקוף את התור הקיים באמבולנסים כל ארבע

```
add_generator("MDA_Supervisor", MDA_Break, when_activated(20), mon=2,priority = 2,preemptible = 3, restart = TRUE)
```

שעות לקחת את האמבולנסים למעבדות.

המסלול שאליו מגיעים מפקחי האמבולנס מהרגע שנוצרו ובו הם תופסים את האמבולנסים:

```
MDA_Break <- trajectory("MDA_Break")%>% ## trajectory that takes out all the ambulances to their break
seize(resource = "MDA",amount=1)%>%
timeout(function () trimmedNorm(15,5))%>% #the time it takes to drive to the lab
timeout(20)%>% #the time it takes to transfer the test to the lab and refill the medical equipment
release("MDA", amount=1)%>%
leave(1)
```

נספח 5.1.10 – מציאת התפלגות קצב הגעת הישויות ל-Drive-In :

תחילה, קראנו את הנתונים מהקובץ שבמודל אל תוכנת Rmarkdown :

```
[r setup, include=FALSE]
knitr::opts_chunk$set(echo = TRUE)

path <- choose.files()
table <- read.csv(path, TRUE)

DIdata <- c(table$DriveIn)

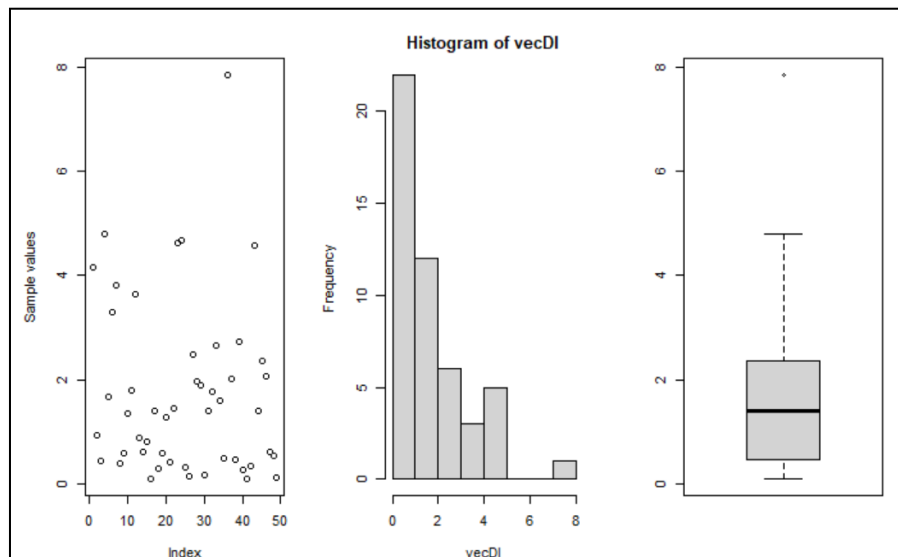
library(chron)

Vnew <- format(strptime(DIdata, "%I:%M:%S %p"), format="%H:%M:%S")
DItmeVec <- 60 * 24 * as.numeric(times(Vnew))

DImat <- data.matrix(DItmeVec)

vecDI <- c()
for (i in 1:length(DItmeVec)-1) {
  vecDI[i] = DImat[i+1,1]-DImat[i,1]
}
...
```

לאחר מכן התבוננו בגרפים המשקפים את הנתונים שלנו:



בחרנו לבדוק האם הנתונים מתפלגים אקספוננציאלית מכיוון שניתן לראות כי הגרף האמצעי מתנהג כמו התפלגות זו ובנוסף מכיוון שזוהי ההתפלגות הכי נפוצה לקצב הגעה.

ביצענו מבחן טיב התאמה עבור ההתפלגות האקספוננציאלית (מבחן קולמוגורוב-סמירנוף) וקיבלנו כי
אנו לא דוחים את המבחן, כלומר הנתונים של קצב ההגעה של הישויות לחד-Drive מתפלגים
אקספוננציאלית עם למדא השווה ל-0.567.

```
{r fitting exp,include=TRUE,echo=FALSE}
expgof<- gofstat(expFit)%>%print()
expgof$skstest%>%print()
...

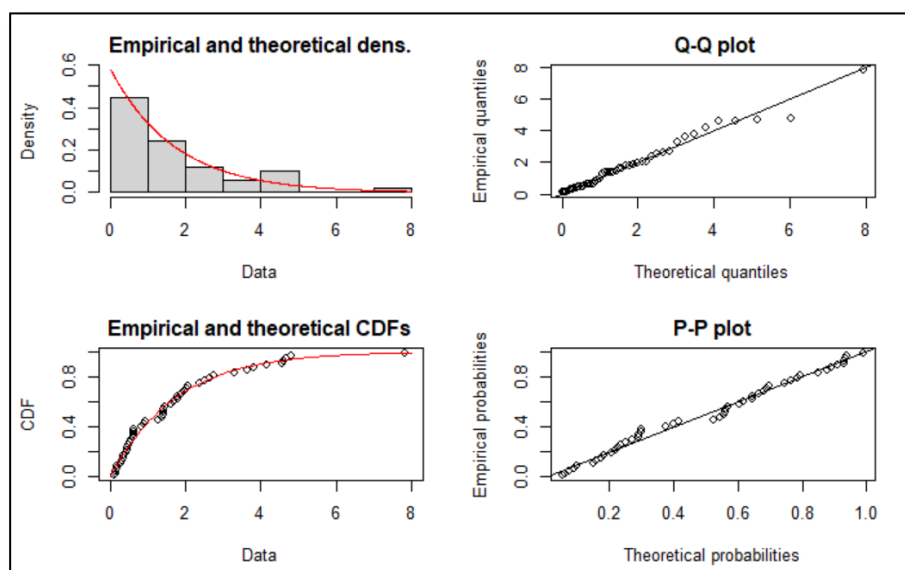
Goodness-of-fit statistics
1-mle-exp
Kolmogorov-Smirnov statistic 0.08755557
Cramer-von Mises statistic 0.04397673
Anderson-Darling statistic 0.33249341

Goodness-of-fit criteria
1-mle-exp
Akaike's Information Criterion 153.5771
Bayesian Information Criterion 155.4689
1-mle-exp
"not rejected"
```

```
{r fitting exp,include=TRUE,echo=FALSE}
expFit$estimate[1]

rate
0.5788541
```

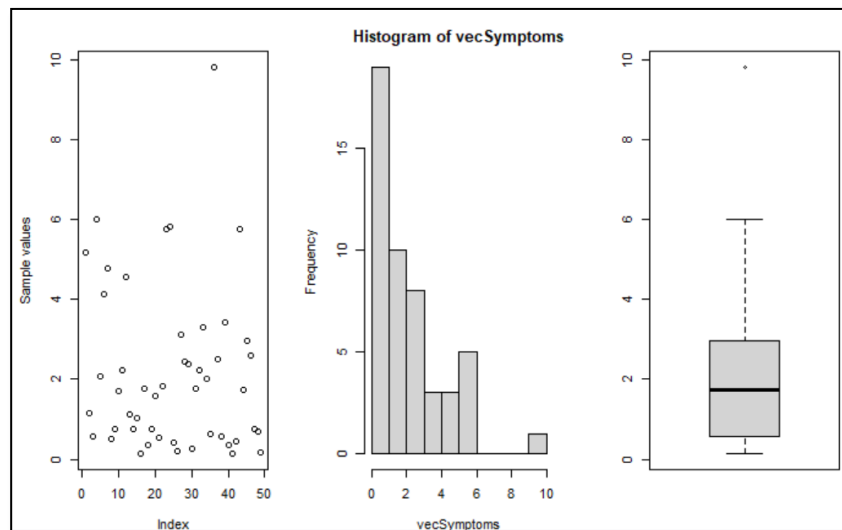
גרפי ההתפלגות שהתקבלה:



נספח 5.1.11 – מציאת התפלגות קצב הגעת הישויות שיש להם סימפטומים למד"א:
תחילה, קראנו את הנתונים מהקובץ שבמודל אל תוכנת Rmarkdown :

```
Didata <- c(table$DriveIn)
library(chron)
Vnew <- format(strptime(Didata, "%I:%M:%S %p"), format="%H:%M:%S")
DitimeVec <- 60 * 24 * as.numeric(times(Vnew))
DImat <- data.matrix(DitimeVec)
vecDI <- c()
for (i in 1:length(DitimeVec)-1) {
  vecDI[i] = DImat[i+1,1]-DImat[i,1]
}
...
```

לאחר מכן התבוננו בגרפים המשקפים את הנתונים שלנו:



בחרנו לבדוק האם הנתונים מתפלגים האקספוננציאלית מכיוון שניתן לראות כי הגרף האמצעי מתנהג כמו התפלגות זו ובנוסף מכיוון שזוהי ההתפלגות הכי נפוצה לקצב הגעה.



ביצענו מבחן טיב התאמה עבור ההתפלגות אקספוננציאלית (מבחן קולמוגורוב-סמירנוף) וקיבלנו כי

אנו לא דוחים את המבחן, כלומר הנתונים של קצב ההגעה של הישויות עם סימפטומים למד"א

מתפלגים אקספוננציאלית עם למדא השווה

0.4637

```
{r fitting exp,include=TRUE,echo=FALSE}
expgof<- gofstat(expFit)%>%print()
expgof$ksstat%>%print()
---
```

Goodness-of-fit statistics

	1-mle-exp
Kolmogorov-Smirnov statistic	0.08887774
Cramer-von Mises statistic	0.04346052
Anderson-Darling statistic	0.33836143

Goodness-of-fit criteria

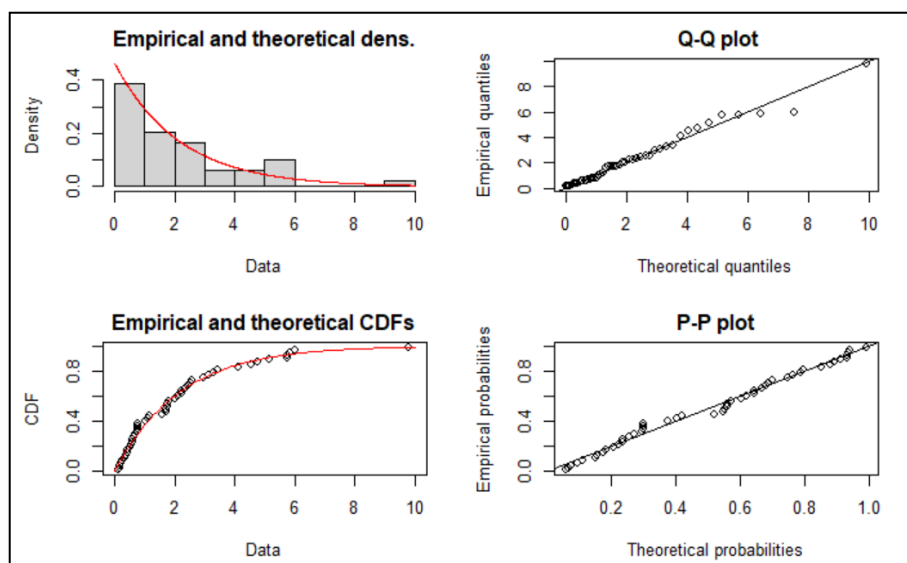
	1-mle-exp
Akaike's Information Criterion	175.4336
Bayesian Information Criterion	177.3254

1-mle-exp
"not rejected"

```
{r fitting exp,include=TRUE,echo=FALSE}
expFit$estimate[1]
```

rate
0.463138

גרפי ההתפלגות שהתקבלה:



נספח 5.1.12 – המשאבים השונים

1. ה-Mini-Drive-In : לכל Mega Drive-In יש כמות שונה של Mini-Drive-In (בצפון ובדרום
3 מיני מתחמים ובמרכז 4 מיני מתחמים), כאשר לכל אחד מהם יש תור שונה אך בכל אחד
יש 3 עמדות.

```
add_resource("N1_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%
add_resource("N2_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%
add_resource("N3_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%

add_resource("C1_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%
add_resource("C2_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%
add_resource("C3_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%
add_resource("C4_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%

add_resource("S1_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%
add_resource("S2_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%
add_resource("S3_mini_drivein",capacity=Full_time_Drivein,queue_size=Inf)%>%
```

לכל Mini-Drive-In יש שעות פעילות מוגדרות, ובכדי ליישם זאת השתמשנו ב-schedule.

```
Full_time_Drivein<-schedule( c(0,6*60,18*60,21*60) , values = c(0,3,2,0), period = 24*60)
```

2. MDA: מרכז אמבולנסים עם תור יחיד המכיל בתוכו 20 אמבולנסים הזמינים לביצוע בדיקות
קורונה ברחבי הארץ.

```
add_resource("MDA",capacity=20,queue_size=Inf,preemptive = FALSE)%>%
```

3. ה-HMO: קופות החולים המפוזרות ברחבי הארץ. בכל אזור יש קופת חולים אחת כאשר
בצפון ובדרום יש 4 עמדות (בכל אחת מהן) ובמרכז יש 7 עמדות.

```
add_resource("HMO_N",capacity=HMO_Sch_N_S,queue_size=Inf)%>%
add_resource("HMO_C",capacity=HMO_Sch_C,queue_size=Inf)%>%
add_resource("HMO_S",capacity=HMO_Sch_N_S,queue_size=Inf)%>%
```

לכל קופת חולים יש זמני פעילות מוגדרים, אך מכיוון על כל קופת חולים לטפל בכל הישויות
שמגיעות אליה עד לשעת הסגירה, אנחנו לא נסגור את הקופות חולים אך כן נפסיק לייצר את
הישויות שמגיעות אליה בזמן הסגירה במדויק.

```
HMO_Sch_N_S <-schedule(c(0,9*60,13*60,14*60), values = c(0,4,0,4),period = 24*60)
HMO_Sch_C <-schedule(c(0,9*60,13*60,14*60), values = c(0,7,0,7),period = 24*60) #
```

4. Labs: 3 מעבדות (מעבדה בכל אזור בארץ), כאשר בכל מעבדה יש 20 עמדות.
הבדיקות שמגיעות למעבדה עומדות בתור, אך בדיקות של ישויות שמגיעות מהקופות חולים
יכולות מכיוון שהן בדיקות תכופות (עם תכונת VIP=1) יכולות לעקוף בתור את הבדיקות
הרגילות שמגיעות ולהיבדק לפני.

```
add_resource("Lab_N",capacity=20,queue_size=Inf,preemptive = FALSE)%>%
add_resource("Lab_C",capacity=20,queue_size=Inf,preemptive = FALSE)%>%
add_resource("Lab_S",capacity=20,queue_size=Inf,preemptive = FALSE)
```

נספח 6.1.1 – מדד אורך תור ממוצע במד"א

קוד חישוב המדד:

```
mda_table <- sqldf("select * from resourceData as re
                    where re.resource in ('MDA') and time>=warming_time ") #Take

#Calculate the average queue length in MDA for each run

mesuresMDAQ_kayam<-c ()
for (i in 1:15) {
  time <- as.matrix(subset(mda_table,replication==i,select=c(time)))
  queueLength <- as.matrix(subset(mda_table,replication==i,select=c(queue)))
  mesuresMDAQ_kayam[i] <- avgQueue(time, queueLength, simulationTime-warming_time)
}
```

עומס התור במד"א מטבלת resource :

	resource	time	server	queue	capacity	queue_size	system	limit	replication
	MDA	All	All	All	All		All		All
60727	MDA	2732.7379	1	55	20	Inf	56	Inf	1
60712	MDA	2730.6451	2	55	20	Inf	57	Inf	1
1548	MDA	561.1122	1	54	20	Inf	55	Inf	1
44337	MDA	2254.1500	1	54	20	Inf	55	Inf	1
60684	MDA	2726.5975	2	54	20	Inf	56	Inf	1
60672	MDA	2724.4372	3	54	20	Inf	57	Inf	1
1508	MDA	559.7132	1	53	20	Inf	54	Inf	1
44336	MDA	2254.1452	1	53	20	Inf	54	Inf	1
1481	MDA	558.7907	2	53	20	Inf	55	Inf	1
60671	MDA	2723.8107	3	53	20	Inf	56	Inf	1
44333	MDA	2253.3499	1	52	20	Inf	53	Inf	1

נספח 6.1.2 – מדד זמן המתנה ממוצע בתור לקופות החולים

קוד חישוב המדד:

```
fullData<-get_mon_arrivals(mm1envs) #avg waiting time at HMO

#Calculation of the average waiting time in the HMO for each run

wt_hmo_kayam <- sqldf("select replication, avg(waiting_time) as wt from (
select fd.replication , (time-start_time-1.5) as waiting_time from fullData as fd join attributedata as ad
on fd.name=ad.name and fd.replication=ad.replication
where ad.key='finished_hmo' and fd.start_time>=warming_time)
group by replication")
```

עומס התורים בקופות החולים מטבלת resource :

	resource	time	server	queue	capacity	queue_size	system	limit	replication
	HMO	All	All	All	All		All		All
24339	HMO_N	1069.188	4	251	4	Inf	255	Inf	1
24419	HMO_N	1070.926	4	251	4	Inf	255	Inf	1
24329	HMO_N	1069.037	4	250	4	Inf	254	Inf	1
24417	HMO_N	1070.913	4	250	4	Inf	254	Inf	1

נספח 6.1.3 – מדד אורך תור ממוצע במעבדת מרכז

קוד חישוב המדד:

```
#avg queue on LabC

lab_table2 <- sqldf("select * from resourceData as re
                    where re.resource in ('Lab_C') and time>=warming_time") #Ta

#Calculate the average queue length in a center lab for each run


mesuresLabQ_kayam<-c ()
for (i in 1:15) {
  time <- as.matrix(subset(lab_table2,replication==i,select=c(time)))
  queueLength <- as.matrix(subset(lab_table2,replication==i,select=c(queue)))
  mesuresLabQ_kayam[i] <- avgQueue(time, queueLength, simulationTime-warming_time)
}
```

עומס התור במעבדת מרכז מטבלת resource :

	resource	time	server	queue	capacity	queue_size	system	limit	replication
57708	Lab_C	2562.465	20	674	20	Inf	694	Inf	1
57707	Lab_C	2562.465	20	673	20	Inf	693	Inf	1
57715	Lab_C	2562.902	20	673	20	Inf	693	Inf	1
57718	Lab_C	2563.248	20	673	20	Inf	693	Inf	1
57706	Lab_C	2562.465	20	672	20	Inf	692	Inf	1
57716	Lab_C	2562.994	20	672	20	Inf	692	Inf	1
57719	Lab_C	2563.350	20	672	20	Inf	692	Inf	1
57705	Lab_C	2562.465	20	671	20	Inf	691	Inf	1
57755	Lab_C	2564.470	20	671	20	Inf	691	Inf	1

נספח 6.2.1 – קביעת זמן החימום עבור הרצת סימולציה של 35 ימים

1. עבור מדד אורך תור ממוצע במד"א





הקוד למציאת הגרף של אורך תור ממוצע במד"א


```
#MDA Queue-----
fullData5 <- get_mon_resources(Covid19)

mda_table2 <- sqldf("select * from fullData5 as re
where re.resource in ('MDA')
" ) #avg queue for mda

averageMDAqueue <- c()
for(i in 1:50400/(24*60)){
  z<- subset(mda_table2,mda_table2$time<i*(24*60))
  averageMDAqueue[i] <- mean(c(z$queue),na.rm=T)
}

plot(vec,averageMDAqueue,xlab = "time", ylab = "Avg MDA queue" )
lines(vec, averageMDAqueue, col="blue",lty=2)
```

2. עבור מדד זמן המתנה ממוצע בתור לקופות החולים



הקוד למציאת הגרף של זמן המתנה ממוצע בקופות חולים

```
#waiting time HMO-----
fullData<-get_mon_arrivals(Covid19)


new <- sqldf("select fd.start_time , (time-start_time-1.5) as waiting_time from fullData as fd join attributedata as ad
on fd.name=ad.name
where ad.key='finished_hmo'")

averageTotalwaiting <- c()
for(i in 1:(50400)/(24*60)){
  x <- subset(new,new$start_time<i*(24*60))
  averageTotalwaiting[i] <- mean(c(x$waiting_time),na.rm=T)
}

plot(vec,averageTotalwaiting,xlab = "time", ylab = "Avg waiting time" )
lines(vec, averageTotalwaiting, col="red",lty=2)
```



3. עבור מדד אורך תור ממוצע במעבדת מרכז



הקוד למציאת הגרף של אורך תור ממוצע במעבדת מרכז

```
#LabC Queue-----
lab_table <- sqldf("select * from resourceData as re
                    where re.resource in ('Lab_C')")

averageLabqueue <- c()
for(i in 1:(50400)/(24*60)){
  z<- subset(lab_table,lab_table$time<=(i*(60*24)))
  averageLabqueue[i] <- mean(c(z$queue),na.rm=T)
}

plot(vec,averageLabqueue,xlab = "time", ylab = "Avg lab c queue" )
lines(vec, averageLabqueue, col="green",lty=2)
```



נספח 6.2.2 – חישוב הדיוק היחסי עבור כל מדד

לצורך קביעת מספר הריצות המינימלי הדרוש עבור בחינת המדדים, בדקנו האם מתקיים אילוץ החסם של

הדיוק היחסי על פי הנוסחה: $\frac{\delta(n, \alpha)}{\bar{X}} \leq \frac{\gamma}{1+\gamma}$. בחרנו את הדיוק היחסי להיות $\gamma=0.12$, עבורו

מתקיים החסם $\frac{\gamma}{1+\gamma} = 0.10714$. בחרנו את רמת המובהקות הכוללת להיות $\alpha_{total} = 0.1$ וחילקנו

במספר המדדים, כך שרמת המובהקות המתקבלת עבור כל מדד היא $\alpha_i = \frac{\alpha_{total}}{n} = \frac{0.1}{3} = 0.033$

ורמת הביטחון היא $1 - \alpha_i = 0.966$

את ערכי הממוצע וסטיית התקן עבור כל המדדים בכל חלופה חישבנו על ידי 15 הרצות.

תוצאות הדיוק היחסי בהשוואה בין כל שתי חלופות, עבור כל מדד, חושבו על פי הנוסחה:

$$\frac{\delta}{\bar{X}} = \frac{t_{(15-1), (1-\frac{0.033}{2})} \cdot \frac{Sd}{\sqrt{15}}}{\bar{X}}$$

נספח 6.2.3 – חישוב דיוק יחסי עבור כל השוואה, ערכי ממוצע וסטיית התקן עבור כל המדדים

פונקציית חישוב הדיוק היחסי והדיוק הגס:

```
n0 <- 15
n <- n0
gamma <- 0.12
alpha_total <- 0.1
alpha_i <- alpha_total/3
t <- qt(1-(alpha_i)/2, n0-1)
gamma_tag <- (gamma)/(1+gamma)

calc_relative_accuracy <- function(mean, sd){
  (t*sd/sqrt(n))/mean
}

number_of_replications <- function(relative_accuracy){
  n*(relative_accuracy/gamma_tag)^2
}
```



יישום פונקציית הדיק היחסי:

```
##first measure mda
c1 <- calc_relative_accuracy(Mean1_kayam_MDA_Q, sd1_kayam_MDA_Q)%>%print()
c2 <- calc_relative_accuracy(Mean1_alternative1_MDA_Q, sd1_alternative1_MDA_Q)%>%print()
c3 <- calc_relative_accuracy(Mean1_alternative2_MDA_Q, sd1_alternative2_MDA_Q)%>%print()

##second measure- avg waiting time HMO
c4 <- calc_relative_accuracy(Mean2_kayam_WT, sd2_kayam_WT)%>%print()
c5 <- calc_relative_accuracy(Mean2_alternative1_WT, sd2_alternative1_WT)%>%print()
c6 <- calc_relative_accuracy(Mean2_alternative2_WT, sd2_alternative2_WT)%>%print()

##third measure- avg Queue at Lab C
c7 <- calc_relative_accuracy(Mean3_kayam_LabC_Q, sd3_kayam_LabC_Q)%>%print()
c8 <- calc_relative_accuracy(Mean3_alternative1_LabC_Q, sd3_alternative1_LabC_Q)%>%print()
c9 <- calc_relative_accuracy(Mean3_alternative2_LabC_Q, sd3_alternative2_LabC_Q)%>%print()
```

דרך חישוב ערכי הממוצע וסטיית התקן עבור כל מדד לכל חלופה

```
#mean and sd for kayam measures
Mean1_kayam_MDA_Q <- mean(data1$kayam_measure1)
sd1_kayam_MDA_Q <- sd(data1$kayam_measure1)
Mean2_kayam_WT <- mean(data1$kayam_measure2)
sd2_kayam_WT <- sd(data1$kayam_measure2)
Mean3_kayam_LabC_Q <- mean(data1$kayam_measure3)
sd3_kayam_LabC_Q <- sd(data1$kayam_measure3)

#mean and sd for alt1 measures
Mean1_alternative1_MDA_Q <- mean(data2$alt1_measure1)
sd1_alternative1_MDA_Q <- sd(data2$alt1_measure1)
Mean2_alternative1_WT <- mean(data2$alt1_measure2)
sd2_alternative1_WT <- sd(data2$alt1_measure2)
Mean3_alternative1_LabC_Q <- mean(data2$alt1_measure3)
sd3_alternative1_LabC_Q <- sd(data2$alt1_measure3)

#mean and sd for alt2 measures
Mean1_alternative2_MDA_Q <- mean(data3$alt2_measure1)
sd1_alternative2_MDA_Q <- sd(data3$alt2_measure1)
Mean2_alternative2_WT <- mean(data3$alt2_measure2)
sd2_alternative2_WT <- sd(data3$alt2_measure2)
Mean3_alternative2_LabC_Q <- mean(data3$alt2_measure3)
sd3_alternative2_LabC_Q <- sd(data3$alt2_measure3)
```

ערכי הממוצע וערכי סטיית התקן:

sd1_alternative1_MDA_Q	0.263219882398551
sd1_alternative2_MDA_Q	1.26347816187858
sd1_kayam_MDA_Q	0.99228565505411
sd2_alternative1_WT	0.0208153548889757
sd2_alternative2_WT	0.45574730493616
sd2_kayam_WT	0.48389733383423
sd3_alternative1_LabC_Q	6.5575980394503
sd3_alternative2_LabC_Q	7.01486149669564
sd3_kayam_LabC_Q	6.36250133272548

Mean1_alternative1_MDA_Q	7.22610868369997
Mean1_alternative2_MDA_Q	6.50580836451071
Mean1_kayam_MDA_Q	8.76612895754086
Mean2_alternative1_WT	2.89140728827334
Mean2_alternative2_WT	22.2972648899262
Mean2_kayam_WT	22.2655068822974
Mean3_alternative1_LabC_Q	123.040092631449
Mean3_alternative2_LabC_Q	140.891016055349
Mean3_kayam_LabC_Q	141.805814803551

30



524	360.1470	Drivein_Clients0	Area	2	1
526	360.7931	Drivein_Clients1	Area	1	1
528	360.8469	Drivein_Clients2	Area	2	1
532	362.8447	Drivein_Clients3	Area	1	1
535	364.0938	Drivein_Clients4	Area	2	1
550	367.1405	Drivein_Clients5	Area	1	1
553	368.0498	Drivein_Clients6	Area	1	1
558	370.1343	Drivein_Clients7	Area	2	1
560	370.3433	Drivein_Clients8	Area	1	1
567	372.8909	Drivein_Clients9	Area	2	1
571	375.9472	Drivein_Clients10	Area	2	1
576	378.1454	Drivein_Clients11	Area	1	1
578	379.4737	Drivein_Clients12	Area	2	1
582	383.7771	Drivein_Clients13	Area	3	1

ניתן לראות כי לקוחות שונים אכן מקבלים תכונות לפי אזורים שונים לאחר החלוקה.

1, North

2, Center

3, South

בנוסף, ניתן לראות כי הגעת לקוח ראשון לפי שעת הפתיחה לדרייב אין היא אחרי 6 בבוקר. (360 דקות)

698	N1_mini_drivein	362.8447	1	0	3
701	C1_mini_drivein	363.0000	0	0	3
699	C2_mini_drivein	363.0000	0	0	3
700	C3_mini_drivein	363.0000	0	0	3
703	C1_mini_drivein	364.0938	1	0	3
704	N1_mini_drivein	364.3447	0	0	3
711	C1_mini_drivein	365.5938	0	0	3
719	N1_mini_drivein	367.1405	1	0	3
721	N2_mini_drivein	368.0498	1	0	3
722	N1_mini_drivein	368.6405	0	0	3
725	N2_mini_drivein	369.5498	0	0	3
727	C1_mini_drivein	370.1343	1	0	3
728	N1_mini_drivein	370.3433	1	0	3

הצלבת הנתונים עם טבלת המשאבים, ניתן לראות כי נתפסו משאבים **בהתאם לאזור ועל פי שעות** הגעת הישויות.

11242	831.1386	Drivein_Clients86	positive	0	1
46084	2560.8832	Drivein_Clients862	positive	1	1
46085	2560.8832	Drivein_Clients863	positive	0	1
46086	2560.8832	Drivein_Clients866	positive	1	1
47257	2627.9626	Drivein_Clients860	positive	0	1
47259	2628.4633	Drivein_Clients867	positive	1	1
47278	2629.5673	Drivein_Clients868	positive	0	1
47958	2717.7041	Drivein_Clients861	positive	0	1
47960	2718.0054	Drivein_Clients865	positive	0	1
47961	2718.6505	Drivein_Clients869	positive	0	1
48674	2797.2222	Drivein_Clients864	positive	1	1

ניתן לראות דגימה מטבלת התכונות אשר לקוחות שונים מקבלים ערכים שונים באם היו חולים או לא

0, Covid19 negative

1, Covid19 positive

ובנוסף החולים מדווחים על הפעלת המחולל –

```
2560.88: Drivein_Clients862: I sent 2 more people for a test
2560.88: Drivein_Clients866: I sent 2 more people for a test
2560.88: Drivein_Clients889: I sent 2 more people for a test
2560.88: Drivein_Clients891: I sent 2 more people for a test
2561.33: Drivein_Clients910: I sent 2 more people for a test
```

2. נבדקי מד"א

(א) לקוח מתקשר למד"א ומקבל תכונה של "סימפטומים", לאחר מכן מקבל תכונה בשעה שבה האמבולנס יצא אליו לדרך (הודעה לנבדק שהאמבולנס בדרכו אליו). לאחר הבדיקה נכנס לbatch וממתין 4 שעות.

(ב) כל 4 שעות (מכניסת הלקוח הראשון), נכנסות 20 ישויות בדמות "מנהל" ושולחות את האמבולנסים להפסקה – **לכל**

אמבולנס זמן נסיעה שונה.

1	MDA_Supervisor13	263.8998	291.8562	23.38722	FALSE	1
2	MDA_Supervisor9	263.8998	292.6653	28.76555	FALSE	1
3	MDA_Supervisor2	263.8998	293.2773	29.37748	FALSE	1
4	MDA_Supervisor7	263.8998	293.3958	29.49600	FALSE	1
5	MDA_Supervisor0	263.8998	294.3754	30.47558	FALSE	1
6	MDA_Supervisor3	263.8998	294.5267	30.62692	FALSE	1
7	MDA_Supervisor4	263.8998	294.5945	30.69467	FALSE	1
8	MDA_Supervisor11	263.8998	295.9692	32.06941	FALSE	1
9	MDA_Supervisor6	263.8998	297.9672	34.06737	FALSE	1
10	MDA_Supervisor5	263.8998	298.9066	35.00676	FALSE	1
11	MDA_Supervisor15	263.8998	299.1256	24.12415	FALSE	1
12	MDA_Supervisor1	263.8998	300.0275	36.12772	FALSE	1
13	MDA_Supervisor8	263.8998	300.9668	37.06702	FALSE	1
14	MDA_Supervisor10	263.8998	303.1362	39.23643	FALSE	1
15	MDA_Supervisor12	263.8998	303.2706	37.13492	FALSE	1
16	MDA_Supervisor14	263.8998	305.6170	35.57604	FALSE	1
17	MDA_Supervisor16	263.8998	310.5528	34.00965	FALSE	1
18	MDA_Supervisor19	263.8998	313.2264	31.11883	FALSE	1
19	MDA_Supervisor17	263.8998	313.9592	35.28345	FALSE	1
20	MDA_Supervisor18	263.8998	317.2926	37.47649	FALSE	1

(ג) בעת הגעת האמבולנסים למעבדות, הלקוחות מופרדים ונכנסים למעבדות השונות בארץ על פי מיקום ארצי (הסתברותי).

(ד) לאחר קבלת תוצאות הבדיקה הלקוח יתנהל בדיוק כפי שתואר **בדריב אין** – סעיף ד'.

בהרצת המצב הקיים נוצרו במד"א 1440 רשומות

ע"פ ההסתברות הנתונה להגעה מכל מקום בארץ נרצה לראות כי אכן נבדקי מד"א חולקו למעבדות השונות ברחבי הארץ באופן הבא –



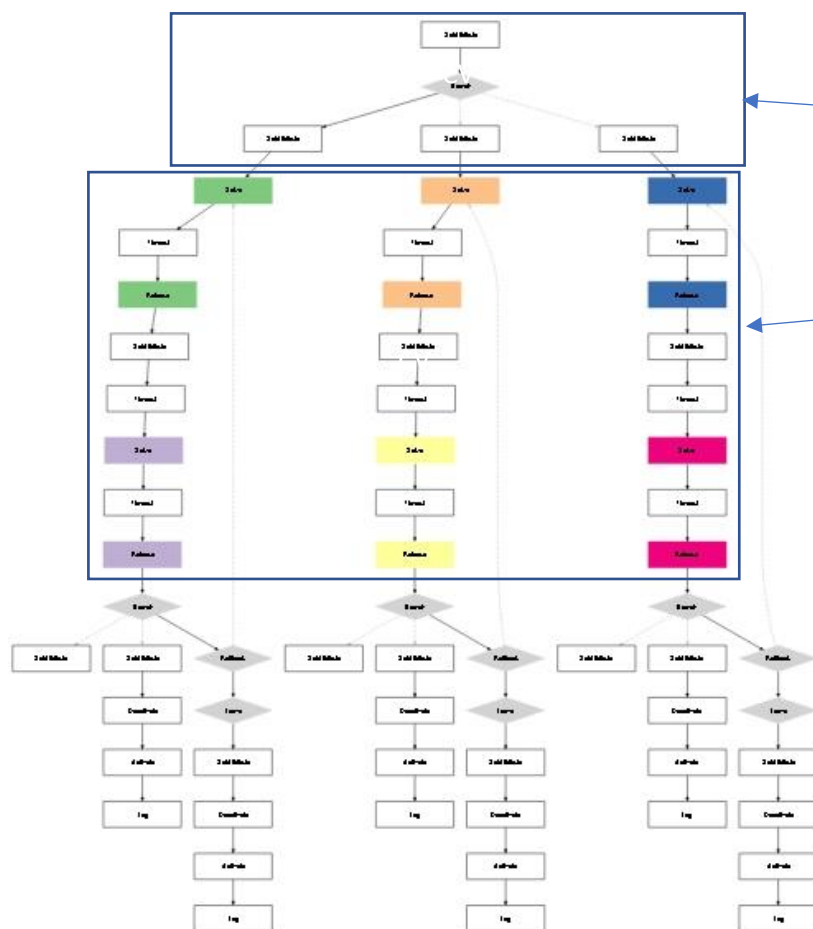
```
> Mda_north_Lab <- sqldf("select count(ad.name) from attributeData as ad
+ where ad.name LIKE ('MDA_Clients%') and ad.key='Area' and ad.value = 1")
>
> paste("The number of MDA clients that arrived north lab is = ", Mda_north_Lab)
[1] "The number of MDA clients that arrived north lab is = 530"
>
> Mda_Center_Lab <- sqldf("select count(ad.name) from attributeData as ad
+ where ad.name LIKE ('MDA_Clients%') and ad.key='Area' and ad.value = 2")
>
> paste("The number of MDA clients that arrived center lab is = ", Mda_Center_Lab)
[1] "The number of MDA clients that arrived center lab is = 589"
>
> Mda_south_Lab <- sqldf("select count(ad.name) from attributeData as ad
+ where ad.name LIKE ('MDA_Clients%') and ad.key='Area' and ad.value = 3")
>
> paste("The number of MDA clients that arrived south lab is = ", Mda_south_Lab)
[1] "The number of MDA clients that arrived south lab is = 321"
```

צפון – 504 ~ 0.35 * 1440

מרכז – 604 ~ 0.42 * 1282

דרום – 334 ~ 504-604 * 1282

3. קופות החולים -



(א) בשלב ראשון מקבלים הנבדקים תכונה של אנשי VIP ומתמיינים על פי הסתברות לאזורים בארץ.

(ב) הבדיקה מתבצעת ומיד אחריה הבדיקות מועברות למעבדה, כאשר מגיעה בדיקה של לקוח VIP הבדיקה מקבלת עדיפות ונכנסת מיד למעבדה.

(ג) לאחר קבלת תוצאות הבדיקה הלקוח יתנהל בדיוק כפי שתואר בדרייב אין – סעיף ד'.

1127	HMO_C	540.0000	0	0	7	Inf	0	Inf	1
1128	HMO_N	540.0000	0	0	4	Inf	0	Inf	1
1129	HMO_S	540.0000	0	0	4	Inf	0	Inf	1

פתיחת המשאב בשעה 09:00:



בדיקת עדיפויות עבור לקוחות VIP במעבדות:

נתנו לישויות שלנו תכונה כשנכנסו וכשסיימו את המעבדה, ניתן לראות כי לקוח שהגיע מהמרפאה

נכנס וסיים לפני לקוח שהגיע ממד"א עקב עדיפות גבוהה יותר

1853	561.1386	MDA_Clients233	Arrived_Lab	1	1	11185	717.6838	MDA_Clients233	left_lab	1	1
1877	561.3357	HMO_Morning_Clients8	Arrived_Lab	1	1	2362	566.4554	HMO_Morning_Clients8	left_lab	1	1

נספח 6.3.2 – ערכי המדדים עבור המצב הקיים

מדד אורך תור ממוצע במעבדת מרכז	מדד זמן המתנה ממוצע בתור לקופות החולים	מדד אורך תור ממוצע במד"א	
141.805	22.265	8.766	ממוצע
6.362	0.483	0.992	סטיית תקן

נספח 6.4.1 – ערכי המדדים עבור חלופה 1

מדד אורך תור ממוצע במעבדת מרכז	מדד זמן המתנה ממוצע בתור לקופות החולים	מדד אורך תור ממוצע במד"א	
123.040	2.891	7.226	ממוצע
6.557	0.020	0.263	סטיית תקן

נספח 6.4.2 – ערכי המדדים עבור חלופה 2

מדד אורך תור ממוצע במעבדת מרכז	מדד זמן המתנה ממוצע בתור לקופות החולים	מדד אורך תור ממוצע במד"א	
140.891	22.297	6.505	ממוצע
7.014	0.455	1.263	סטיית תקן



נספח 6.5.1 – מבחני t מזווג להשוואת חלופות

מבחן t מזווג עבור מדד אורך תור ממוצע במד"א

```
Q_MDA_Kayam_VS_alt1<- t.test(x= data1$kayam_measure1,y=data2$alt1_measure1, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(Q_MDA_Kayam_VS_alt1)

Q_MDA_Kayam_VS_alt2<- t.test(x= data1$kayam_measure1,y= data3$alt2_measure1, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(Q_MDA_Kayam_VS_alt2)

Q_MDA_alt1_VS_alt2<- t.test(x= data2$alt1_measure1,y=data3$alt2_measure1, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(Q_MDA_alt1_VS_alt2)
```

מבחן t מזווג עבור מדד זמן המתנה ממוצע בתור לקופות החולים

```
wt_HMO_Kayam_VS_alt1<- t.test(x= data1$kayam_measure2,y=data2$alt1_measure2, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(wt_HMO_Kayam_VS_alt1)

wt_HMO_Kayam_VS_alt2<- t.test(x= data1$kayam_measure2,y=data3$alt2_measure2, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(wt_HMO_Kayam_VS_alt2)

wt_HMO_alt1_VS_alt2<- t.test(x= data2$alt1_measure2,y=data3$alt2_measure2, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(wt_HMO_alt1_VS_alt2)
```

מבחן t מזווג עבור מדד אורך תור ממוצע במעבדת מרכז

```
Q_LabC_Kayam_VS_alt1<- t.test(x= data1$kayam_measure3,y=data2$alt1_measure3, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(Q_LabC_Kayam_VS_alt1)

Q_LabC_Kayam_VS_alt2<- t.test(x= data1$kayam_measure3,y=data3$alt2_measure3, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(Q_LabC_Kayam_VS_alt2)

Q_LabC_alt1_VS_alt2<- t.test(x= data2$alt1_measure3,y=data3$alt2_measure3, alternative="two.sided",paired=TRUE,var.equal=TRUE,conf.level=conf.lv1)
print(Q_LabC_alt1_VS_alt2)
```